École Centrale Lyon

Nouvelles technologies de l'information et de la communication

Stratégie de veille

Rapport

Le super-cycle de la mémoire vive

Élèves :

Jean-Joseph TAMPE

Enseignant :

Mohsen ARDABILIAN

9 avril 2026

0 Table des matières

1 Introduction et cadrage stratégique **3**
1.1 Contexte et problématique . . . 3
1.2 Objectifs de la veille . . . 3

2 Périmètre et sélection des sources **4**
2.1 Critères de sélection . . . 4
2.2 Corpus de 27 sources surveillées . . . 4
2.3 Limites de couverture . . . 6

3 Méthodologie de traitement de l'information **7**
3.1 Vue d'ensemble du pipeline automatisé . . . 7
3.2 Critères de pertinence automatique . . . 7
3.3 Analyse par modèle de langage local (Llama 3.1 8B) . . . 8
3.3.1 Choix du modèle et justification . . . 8
3.3.2 Structure de l'analyse . . . 8
3.4 Synthèse hebdomadaire par entreprise . . . 9

4 Résultats et analyse **10**
4.1 Vue d'ensemble du corpus . . . 10
4.2 Les acteurs de l'oligopole DRAM/HBM . . . 10
4.2.1 SK Hynix . . . 10
4.2.2 Samsung Electronics . . . 10
4.2.3 Micron Technology . . . 10
4.3 Tendances techniques identifiées . . . 11
4.3.1 Le super-cycle HBM : de la HBM3E à la HBM4 . . . 11
4.3.2 CXL : l'interconnexion mémoire de prochaine génération . . . 11
4.3.3 Processing-In-Memory (PIM) . . . 11
4.4 Corrélation technique et financière . . . 11

5 Éthique et propriété intellectuelle **12**
5.1 Respect du droit d'auteur . . . 12
5.2 Traitement différencié selon les licences . . . 12
5.3 Données personnelles et confidentialité . . . 12

6 Conclusion et perspectives **13**
6.1 Bilan . . . 13
6.2 Limites . . . 13
6.3 Perspectives . . . 13

A Architecture logicielle du système MemoryWall Monitor **15**
A.1 Stack technique 15
A.2 Schéma de la base de données 15
A.3 Prompts Llama complets 16
A.3.1 System prompt (persona expert) 16
A.3.2 Prompt d'analyse article 17
A.3.3 Prompt de synthèse hebdomadaire 17
A.4 Liste complète des mots-clés de pertinence 18

1 Introduction et cadrage stratégique

1.1 Contexte et problématique

Le développement des grands modèles de langage (*Large Language Models*, LLM) a suivi, depuis 2018, une trajectoire de croissance exponentielle du nombre de paramètres : GPT-2 (2019, 1,5 milliard de paramètres), GPT-3 (2020, 175 milliards), LLaMA-3 (2024, 405 milliards), avec des modèles récents dépassant le millier de milliards. Cette progression, de l'ordre d'un facteur 10 par an, se heurte à une limite physique fondamentale : la **bande passante mémoire**, qui ne progresse que d'un facteur 1,3 par an.

Ce déséquilibre structurel porte un nom : le **Memory Wall**. À chaque token généré, un modèle de langage doit lire la totalité de ses poids depuis la mémoire vive. Un modèle de 70 milliards de paramètres en BF16 occupe ∼140 Go de mémoire GPU : générer un seul token revient à déplacer l'intégralité de ces données depuis la mémoire vers les unités de calcul. L'opération est dite *memory-bound* — la mémoire, et non la puissance de calcul, est le facteur limitant.

1.2 Objectifs de la veille

Cette veille technologique, accessible à l'adresse `https://jeanjosephtampe-create.github.io/memorywall-monitor/`, poursuit trois objectifs complémentaires :

1. **Surveiller l'innovation technique** : nouvelles générations de mémoire haute bande passante (HBM3E, HBM4), techniques d'optimisation (quantisation, KV cache, Flash Attention), architectures émergentes (PIM, CXL).
2. **Suivre les dynamiques de marché** : capacités de production des fonderies, prix de la DRAM, parts de marché des trois acteurs principaux (SK Hynix, Samsung, Micron).
3. **Anticiper les mouvements stratégiques** : partenariats industriels, contrats avec les hyperscalers (Microsoft, Google, Meta), signaux boursiers.

2 Périmètre et sélection des sources

2.1 Critères de sélection

Les sources ont été sélectionnées selon quatre critères :

- **Autorité** : la source est reconnue dans son domaine (comité de lecture pour arXiv, indépendance éditoriale pour SemiAnalysis, légitimité institutionnelle pour les newsrooms constructeurs).
- **Fraîcheur** : publication régulière, flux RSS actif, délai de mise à jour inférieur à 24 heures pour les alertes d'actualité.
- **Couverture géographique** : le marché de la mémoire est dominé par des acteurs coréens (SK Hynix, Samsung) et américains (Micron). Des sources en français, anglais et des alertes ciblées couvrent les trois régions.
- **Diversité des angles** : recherche académique, analyse de marché, presse technologique grand public, communication officielle des entreprises.

2.2 Corpus de 27 sources surveillées

Source	Catégorie	Type	Justification
arXiv · Computer Architecture	Recherche	Académique	Prépublications sur l'architecture des systèmes mémoire et des accélérateurs
arXiv · Machine Learning	Recherche	Académique	Prépublications sur les techniques d'optimisation mémoire pour LLM
SemiAnalysis	Analyse	Indépendant	Référence pour l'analyse approfondie des semiconducteurs et de l'IA hardware
The Next Platform	Analyse	Indépendant	Datacenters, HPC, analyse des architectures mémoire en production
Interconnects (N. Lambert)	Analyse	Indépendant	Recherche RL et LLM, angle inference et efficacité
The Gradient	Analyse	Indépendant	Articles approfondis sur la recherche en IA

(suite du tableau des sources)

Source	Catégorie	Type	Justification
TrendForce Semiconductor	Analyse	Étude de marché	Données de marché DRAM, NAND, prévisions tarifaires
TrendForce Press Center	Analyse	Étude de marché	Communiqués de presse TrendForce
MIT Technology Review AI	Presse	Presse spécialisée	Couverture de référence grand public et scientifique
IEEE Spectrum AI	Technique	Professionnel	Ingénierie et innovation technique, point de vue IEEE
Hugging Face Blog	Industrie	Corporate	Publications de la communauté ML open-source
SK Hynix Newsroom	Constructeur	Corporate	Annonces officielles SK Hynix (HBM, DRAM, TSV)
Samsung Global News	Constructeur	Corporate	Annonces officielles Samsung Electronics (mémoire, fonderie)
Micron Investor News	Constructeur	Corporate	Publications financières et techniques Micron
JEDEC Standards News	Standard	Organisme	Nouvelles normes HBM4, DDR6, LPDDR6
Google Alert · HBM	Veille	Alerte auto.	Couverture temps réel de toute mention « HBM »
Google Alert · HBM4	Veille	Alerte auto.	Suivi de la prochaine génération HBM
Google News FR · HBM	Veille FR	Agrégateur	Actualité HBM/DRAM en langue française
Google News US · HBM	Veille US	Agrégateur	Actualité HBM/DRAM en langue anglaise
Google News FR · HBM4	Veille FR	Agrégateur	Actualité HBM4 en langue française
Google News US · HBM4	Veille US	Agrégateur	Actualité HBM4 en langue anglaise

(suite du tableau des sources)

Source	Catégorie	Type	Justification
Google News FR · DRAM	Veille FR	Agrégateur	Marché DRAM global, sources francophones
Google News US · DRAM	Veille US	Agrégateur	Marché DRAM global, sources anglophones
Google News FR · VRAM IA	Veille FR	Agrégateur	Besoins mémoire GPU pour l'IA, presse FR
Google News US · VRAM AI	Veille US	Agrégateur	Besoins mémoire GPU pour l'IA, presse US
Google News FR · Samsung HBM	Veille FR	Agrégateur	Samsung + mémoire, presse française
Google News US · Samsung HBM	Veille US	Agrégateur	Samsung + mémoire, presse américaine

2.3 Limites de couverture

Trois limites ont été identifiées et assumées :

— **Sources coréennes** : les principaux acteurs (SK Hynix, Samsung) publient une partie de leur communication en coréen. Ces articles ont été exclus du traitement automatique, le modèle Llama 3.1 8B n'étant pas optimisé pour cette langue.
— **Sources payantes** : des rapports d'analystes (IDC, Gartner, IC Insights) apporteraient des données quantitatives de référence mais sont hors d'accès étudiant.
— **Biais anglophone** : la majorité des sources est en anglais ; la couverture francophone reste partielle et secondaire.

3 Méthodologie de traitement de l'information

3.1 Vue d'ensemble du pipeline automatisé

Le système *MemoryWall Monitor* implémente un pipeline en cinq phases s'exécutant quotidiennement à 3h UTC :

```
[Phase 1] COLLECTE RSS (1-2 min)
   27 flux recuperes en parallele
   Scraping HTML si contenu RSS < 500 caracteres
   Deduplication par hash MD5 de l'URL
   Score de pertinence preliminaire (0-10)
         |
         v
[Phase 2] ANALYSE IA - Llama 3.1 8B (20-50 min)
   Articles tries par score decroissant
   2 articles analyses en parallele
   Contenu tronque a 4000 caracteres
   Sortie JSON : resume, points cles, score, tags
         |
         v
[Phase 3] SYNTHESES HEBDOMADAIRES (3-5 min)
   Regroupement par semaine ISO x entreprise
   Bullets Tech (2-4) + Eco (1-3) + score sentiment
   Contexte des 2 semaines precedentes injecte
         |
         v
[Phase 4] DIGEST EDITORIAL (30 sec)
   Top 5 articles -> synthese editoriale 3-4 paragraphes
         |
         v
[Phase 5] DONNEES FINANCIERES
   7 tickers (yfinance) : MU, 000660.KS, 005930.KS,
   SOXX, SMH, NVDA, AMD
```

Listing 1 – Pipeline de traitement automatisé

3.2 Critères de pertinence automatique

Un premier filtre, purement lexical, est appliqué avant toute sollicitation du LLM. Plus de 70 mots-clés thématiques sont organisés en six catégories :

— **Memory Wall** : *memory wall, memory bandwidth, memory bottleneck, memory-bound, memory hierarchy, bande passante mémoire...*

— **Hardware** : *HBM, HBM3E, HBM4, DRAM, DDR5, LPDDR5, TSV, CoWoS, interposeur, 2.5D packaging...*
— **Optimisation** : *quantization, pruning, distillation, flash attention, paged attention, KV cache, model compression...*
— **Architecture** : *transformer memory, scaling law, arithmetic intensity, roofline model, compute express link, CXL, PIM...*
— **Entreprises** : *SK Hynix, Samsung memory, Micron, NVIDIA, AMD GPU...*
— **Inférence LLM** : *inference latency, token per second, throughput, context window, batch size...*

Chaque occurrence dans le titre ou le contenu ajoute +2 points au score (plafonné à 10). Ce score détermine la priorité d'analyse par le LLM, les ressources étant limitées.

3.3 Analyse par modèle de langage local (Llama 3.1 8B)

3.3.1 Choix du modèle et justification

Llama 3.1 8B [**llama31**] a été retenu pour trois raisons principales :

1. **Confidentialité** : le traitement s'effectue entièrement en local (via Ollama), sans transmission des articles à un service tiers.
2. **Coût nul** : modèle open-source, aucune facturation à l'inférence.
3. **Adéquation à la tâche** : l'analyse d'article court (< 4000 caractères) ne nécessite pas un modèle de plus grande taille.

3.3.2 Structure de l'analyse

Le modèle reçoit un *system prompt* le positionnant comme expert en Memory Wall et inférence LLM, puis le contenu de l'article. La réponse attendue est un JSON structuré :

— **titre_court** : reformulation synthétique (< 10 mots)
— **resume** : synthèse factuelle en 2–3 phrases
— **lien_memory_wall** : explicitation du lien avec la problématique centrale
— **points_cles** : tableau de 3 points clés
— **score_pertinence** : note entière de −10 à +10
— **tags** : tableau de 3+ étiquettes thématiques

Paramètres d'inférence : température 0,3, top_p 0,9, 900 tokens maximum. En cas d'échec de parsing JSON, un mécanisme de réparation en 5 niveaux est appliqué (extraction du bloc JSON, nettoyage syntaxique, équilibrage des accolades, extraction regex).

3.4 Synthèse hebdomadaire par entreprise

Au-delà de l'analyse article par article, un deuxième niveau d'analyse agrège les articles d'une semaine ISO par entreprise. Le LLM produit :

- 2 à 4 **bullets techniques** (faits chiffrés, annonces produits)
- 1 à 3 **bullets économiques** (contrats, résultats financiers, partenariats)
- Un **score de sentiment** de -10 à $+10$: positif si les nouvelles sont favorables à l'entreprise surveillée (hausse de capacité, nouveau contrat, avance technique), négatif en cas de pénurie, perte de marché ou retard technologique.

Le contexte des deux semaines précédentes est injecté dans le prompt pour assurer la continuité et éviter la répétition d'une semaine à l'autre.

4 Résultats et analyse

4.1 Vue d'ensemble du corpus

Au moment de la rédaction de ce rapport, la base de données accumule les statistiques suivantes :

Indicateur	Valeur
Articles collectés (total)	1 433
Articles analysés par Llama 3.1 8B	781 (54,5 %)
Flux RSS actifs	27
Entreprises détectées	14
Semaines de recaps générés	12
Tickers boursiers suivis	7

4.2 Les acteurs de l'oligopole DRAM/HBM

Le marché de la DRAM est structurellement concentré : trois entreprises se partagent la quasi-totalité de la production mondiale.

4.2.1 SK Hynix

SK Hynix est, en 2025–2026, le leader incontesté du marché de la HBM. L'entreprise coréenne produit la mémoire HBM3E équipant les GPU H100 et H200 de NVIDIA, et est en avance sur le développement de la HBM4. Sa valorisation boursière (ticker : 000660.KS, KRX) reflète directement les cycles de commande des hyperscalers.

4.2.2 Samsung Electronics

Samsung, premier producteur mondial de DRAM toutes générations confondues, accuse un retard sur la HBM3E comparé à SK Hynix. L'entreprise cherche à rattraper ce retard via des investissements massifs en TSV (*Through-Silicon Via*) et en fonderie avancée (3 nm). Son ticker 005930.KS est un indicateur large du secteur semiconducteurs coréen.

4.2.3 Micron Technology

Micron (NASDAQ : MU) est le seul acteur américain. L'entreprise monte en puissance sur la HBM3E et bénéficie du soutien politique américain (CHIPS Act) pour réduire la dépendance aux fournisseurs asiatiques. Ses publications trimestrielles sont des événements majeurs pour anticiper les prix de la DRAM.

4.3 Tendances techniques identifiées

4.3.1 Le super-cycle HBM : de la HBM3E à la HBM4

La transition vers la HBM4 représente la principale discontinuité technologique suivie par cette veille. La HBM4 double la bande passante par stack (∼2 To/s contre ∼1,2 To/s pour la HBM3E) grâce à une augmentation du nombre de layers (16 dies) et à une réduction du pas du TSV. SK Hynix vise une livraison en 2025, Samsung et Micron suivent en 2026.

4.3.2 CXL : l'interconnexion mémoire de prochaine génération

Le standard *Compute Express Link* (CXL 3.0) permet d'attacher de la mémoire additionnelle au CPU/GPU via le bus PCIe, avec une latence bien inférieure à la DRAM externe classique. Plusieurs acteurs (Samsung, Micron, startups comme Astera Labs) développent des modules CXL qui pourraient alléger la contrainte du Memory Wall pour les charges d'inférence de grande taille.

4.3.3 Processing-In-Memory (PIM)

La PIM vise à effectuer des calculs directement au sein de la puce mémoire, éliminant le transit de données entre mémoire et unités de calcul. SK Hynix a démontré un prototype DRAM-PIM pour l'inférence LLM en 2024. Cette approche constitue potentiellement une rupture de paradigme, mais reste limitée par la complexité de programmation.

4.4 Corrélation technique et financière

L'intérêt d'un suivi simultané des cours boursiers et de l'actualité technique est de mettre en évidence les **catalyseurs d'événements**. Plusieurs patterns ont été observés sur la période de veille :

- Les annonces de résultats trimestriels de Micron (typiquement fin mars, juin, septembre, décembre) entraînent une volatilité immédiate sur MU, avec une corrélation sur 000660.KS et 005930.KS dans les 24–48h.
- Les annonces de commandes massives par les hyperscalers (projet Stargate, contrats Microsoft/Google avec SK Hynix) induisent des hausses de cours déconnectées des fondamentaux trimestriels.
- Les ETF sectoriels SOXX et SMH offrent un signal de sentiment global sur le secteur semiconducteur, préalable aux mouvements sur les valeurs individuelles.

5 Éthique et propriété intellectuelle

5.1 Respect du droit d'auteur

La veille automatisée s'appuie sur des flux RSS publiquement diffusés par leurs éditeurs, ce qui constitue un mode d'accès légal à l'information. Les principes suivants ont été rigoureusement appliqués :

— **Aucune republication de contenu** : les articles ne sont pas reproduits intégralement. Seuls des résumés et extraits sont stockés en base de données locale, à des fins d'analyse personnelle non commerciale.
— **Liens systématiques vers la source originale** : toute synthèse ou analyse pointe vers l'URL d'origine, préservant les droits de l'auteur et permettant la vérification.
— **Analyse transformative** : les résumés produits par le LLM constituent une *oeuvre dérivée transformative* au sens du droit français (article L122-5 du Code de la propriété intellectuelle), ce qui les distingue d'une reproduction illicite.

5.2 Traitement différencié selon les licences

Source	Licence	Usage dans la veille
arXiv	CC BY 4.0	Résumé et analyse autorisés, attribution systématique
Presse (MIT TR, IEEE)	Copyright	Résumé court uniquement ; pas de reproduction
TrendForce	Propriétaire	Données citées et référencées, non reproduites
Corporate (SK Hynix, Samsung, Micron)	Copyright	Synthèse des annonces officielles
Google Alerts	Agrégateur	Pointe vers sources primaires

5.3 Données personnelles et confidentialité

Le traitement des articles s'effectue entièrement en local (base SQLite, inférence Ollama). Aucune donnée n'est transmise à un service tiers commercial. Les clés API éventuelles (services externes) ne figurent pas dans le dépôt public du projet.

6 Conclusion et perspectives

6.1 Bilan

Cette veille démontre la faisabilité d'un **système d'intelligence technologique automatisé, reproductible et économe en ressources**. En combinant la collecte RSS multi-sources, un LLM local pour l'analyse sémantique et un suivi financier temps réel, il est possible de traiter quotidiennement plusieurs centaines d'articles et d'en extraire une synthèse structurée en moins d'une heure de calcul.

Sur le fond, la veille confirme que le Memory Wall constitue bien la contrainte principale au déploiement à l'échelle des LLM. La réponse industrielle (HBM4, CXL, PIM) est en cours, mais la cadence d'innovation matérielle reste structurellement inférieure à celle des modèles. Les trois producteurs (SK Hynix, Samsung, Micron) se retrouvent en position de pouvoir sur une ressource stratégique, avec des conséquences directes sur les prix de la DRAM grand public.

6.2 Limites

- **Modèle 8B** : Llama 3.1 8B produit des analyses de qualité variable sur les articles très techniques ; des modèles plus grands (70B+) ou spécialisés seraient plus pertinents.
- **Biais des sources** : la prédominance de sources anglophones introduit un angle de vue occidental. Les stratégies Samsung et SK Hynix sont partiellement filtrées faute de sources coréennes traitables.
- **Absence de sources payantes** : les rapports d'analystes (IDC, SEMI) apporteraient des données quantitatives que les flux RSS ne fournissent pas.

6.3 Perspectives

- Intégration d'un système d'alertes par email lors de la détection d'articles à score élevé, pour une veille réactive.
- Extension du périmètre à des sujets adjacents : optique pour les interconnexions (photonique), architectures neuromorphiques, mémoire résistive (RRAM).
- Passage à un modèle d'analyse plus grand pour les articles à fort score de pertinence, en conservant le 8B pour le pré-filtrage.

6 Références

[1] AI@Meta, *The Llama 3 Herd of Models*, arXiv :2407.21783, 2024. https://arxiv.org/abs/2407.21783

[2] Dao, T. et al., *FlashAttention-2 : Faster Attention with Better Parallelism and Work Partitioning*, arXiv :2307.08691, 2023. https://arxiv.org/abs/2307.08691

[3] Wulf, W. A. & McKee, S. A., *Hitting the Memory Wall : Implications of the Obvious*, ACM SIGARCH Computer Architecture News, 23(1), 1995.

[4] SK Hynix Newsroom, *SK Hynix HBM Roadmap — HBM4 Development Update*, 2025. https://news.skhynix.com

[5] TrendForce, *OpenAI's Stargate 900K DRAM Wafers Could Hit 40% of Global Output*, TrendForce, 2 octobre 2025. https://www.trendforce.com/news/2025/10/02/

[6] CXL Consortium, *Compute Express Link Specification Revision 3.0*, 2023. https://www.computeexpresslink.org

[7] Williams, S., Waterman, A. & Patterson, D., *Roofline : An Insightful Visual Performance Model for Floating-Point Programs and Multicore Architectures*, CACM, 52(4), 2009.

A Architecture logicielle du système MemoryWall Monitor

A.1 Stack technique

Couche	Technologie	Rôle
Serveur HTTP	FastAPI + Uvicorn	Exposition des API REST et service des pages
Base de données	SQLite 3	Stockage articles, analyses, recaps, paramètres
IA locale	Ollama + Llama 3.1 8B	Analyse sémantique et synthèse
RSS	feedparser 6.0.11	Collecte et parsing des flux
HTTP client	httpx (async)	Scraping asynchrone
HTML parsing	BeautifulSoup4 + lxml	Extraction du contenu utile
Cours boursiers	yfinance 1.2.0	Données Yahoo Finance
Graphiques	matplotlib 3.9.3	Génération PNG côté serveur
Planification	APScheduler 3.10.4	Déclenchement automatique quotidien
Frontend	HTML5 / CSS3 / Vanilla JS	Interface web sans framework
Charts frontend	Chart.js	Graphiques interactifs côté navigateur

A.2 Schéma de la base de données

Cinq tables SQLite structurent la persistance :

```
-- Articles collectes et analyses
articles (
  id             TEXT PRIMARY KEY,  -- MD5(url), 12 chars
  title          TEXT,
  url            TEXT,
  content        TEXT,              -- max 10 000 caracteres
  date           TEXT,              -- ISO 8601
  feed_category  TEXT,
  relevance_score INTEGER,          -- 0 a 10 (mots-cles)
  companies      TEXT,              -- JSON array
  analysis       TEXT               -- JSON Llama
);

-- Cache des cours boursiers
```

```sql
stocks_cache (
  ticker  TEXT,
  date    TEXT,
  open, high, low, close  REAL,
  volume  INTEGER,
  PRIMARY KEY (ticker, date)
);

-- Syntheses hebdomadaires par entreprise
recap_summaries (
  week          TEXT,              -- "2025-W03"
  company       TEXT,
  tech_bullets  TEXT,              -- JSON array
  eco_bullets   TEXT,              -- JSON array
  score         INTEGER,           -- -10 a +10
  PRIMARY KEY (week, company)
);

-- Mots-cles de pertinence (editables)
keywords (keyword TEXT UNIQUE, category TEXT, active INTEGER);

-- Parametres de configuration
settings (key TEXT PRIMARY KEY, value TEXT);
```

Listing 2 – Schéma simplifié — tables principales

A.3 Prompts Llama complets

A.3.1 System prompt (persona expert)

```
Tu es un analyste expert en architecture informatique et intelligence
   artificielle,
specialise dans la problematique du Memory Wall     le goulot d'
   etranglement que
represente la memoire vive pour les grands modeles de langage (LLM).

Le Memory Wall designe le fait que la vitesse et la bande passante
   memoire progressent
beaucoup plus lentement que le nombre de parametres des LLM, creant un
   desequilibre
structurel qui limite les performances et l'inference.

Ta mission : analyser des articles techniques et produire des syntheses
   claires,
structurees et pertinentes pour un lecteur expert mais pas
   necessairement
```

```
specialiste hardware.
```

Listing 3 – System prompt — analyse d'articles

A.3.2 Prompt d'analyse article

```
Analyse cet article et reponds UNIQUEMENT en JSON valide, sans
   commentaires.

Titre : {title}
Contenu : {content}

Format attendu :
{
  "titre_court": "< 10 mots, percutant",
  "resume": "2-3 phrases factuelles",
  "lien_memory_wall": "1-2 phrases ou null",
  "points_cles": ["point 1", "point 2", "point 3"],
  "score_pertinence": <entier -10 a +10>,
  "tags": ["tag1", "tag2", "tag3"]
}
```

Listing 4 – Template d'analyse d'article

A.3.3 Prompt de synthèse hebdomadaire

```
Tu es analyste specialise memoire et semiconducteurs.
Voici les articles de la semaine {week} concernant {company}.

{articles_content}

Contexte des semaines precedentes :
{prev_context}

Reponds UNIQUEMENT en JSON :
{
  "tech": ["bullet technique 1 (< 12 mots)", "bullet 2"],
  "eco":  ["bullet economique 1 (< 12 mots)"],
  "score": <entier -10 a +10>
}

Regles : faits uniquement, chiffres et specs si disponibles,
distingue des semaines precedentes.
```

Listing 5 – Template de recap hebdomadaire

A.4 Liste complète des mots-clés de pertinence

Memory Wall
memory wall
memory bandwidth
memory bottleneck
memory-bound
memory hierarchy
bandwidth utilization

Hardware
HBM, HBM2E, HBM3
HBM3E, HBM4
high bandwidth memory
DRAM, DDR4, DDR5
LPDDR5, SRAM
GPU memory, VRAM
CoWoS, interposeur
2.5D packaging
TSV, wafer

Optimisation
quantization / quantisation
pruning, distillation
model compression
flash attention
paged attention
KV cache
memory offloading

Architecture
transformer memory
attention memory
scaling law
arithmetic intensity
roofline model
CXL, PIM
near-memory computing
neuromorphic

Entreprises
SK Hynix, Hynix
Samsung memory
Micron, Crucial
NVIDIA, NVDA, CUDA
AMD GPU
TSMC, Intel

Inférence LLM
inference latency
token per second
throughput
batch size
context window
sequence length
memory efficiency